

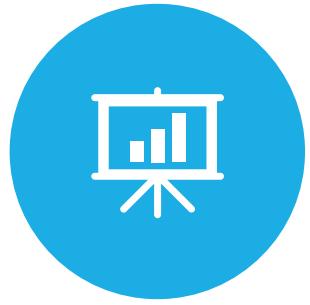
การรวมข้อมูล การจัดหาข้อมูล การเตรียมข้อมูล

วิทยาการข้อมูลเบื้องต้น
(Fundamentals of Data Science)

ผศ.ดร.ธิติพร ชาญศิริวัฒน์



DATA SOURCE

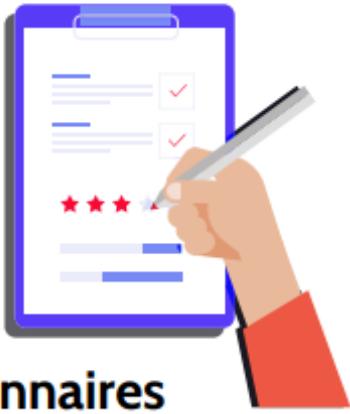


**DATA
REPRESENTATION**



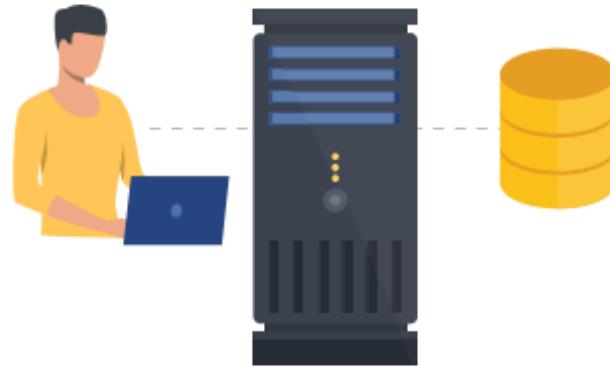
DATA CLEANSING

DATA SOURCE



Questionnaires

- Paper-based questionnaires
- Electronic-based questionnaires
- Online questionnaires



Web Servers

Server software, or hardware dedicated to running said software, that can satisfy World Wide Web client requests.



Web Services

A service offered by an electronic device to another electronic device, communicating with each other via the World Wide Web

DATA SOURCE



Database

An organized collection of data, generally stored and accessed electronically from a computer system



Logs

- Records of events.
- In computer, for example, a file that records either events that occur in an operating system or other software runs, or messages between different users of a communication software.



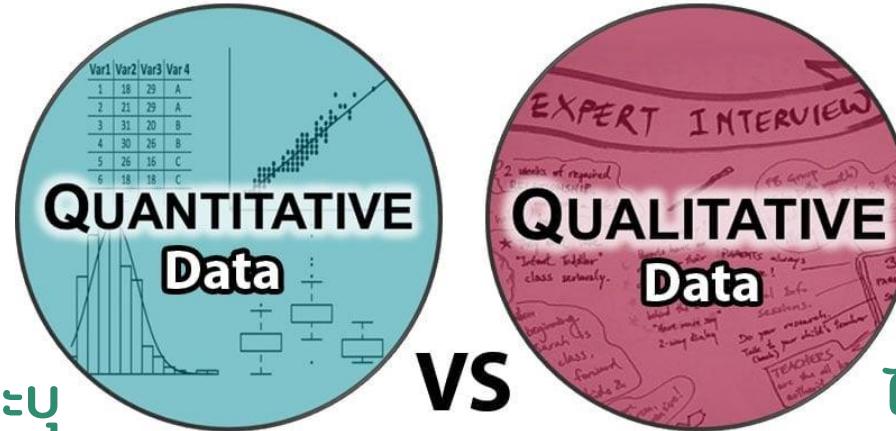
Online Repositories

- A repository is a central place in which an aggregation of data is kept and maintained in an organized way, usually in computer storage.
- An online repository is a digital library or archive which is accessible via the internet.

TYPES OF DATA

ข้อมูลเชิงปริมาณ
หรือ ข้อมูลเชิงตัวเลข
(Numerical data)

ข้อมูลในลักษณะตัวเลขต่างๆ ระบุ
ถึงความมากน้อยในเชิงปริมาณ
ข้อมูลด้วยค่าต่างๆ



ข้อมูลเชิงคุณภาพ
หรือ ข้อมูลเชิงกลุ่ม
(Categorical data)

ไม่สามารถวัดค่าด้วยอุปกรณ์ มัก
อยู่ในรูปแบบข้อความ หรือตัว
เลขที่ไม่มีความหมายเชิงปริมาณ

- Discrete data (ข้อมูลแบบไม่ต่อเนื่อง): ข้อมูลที่นับได้และมีค่าไม่ต่อเนื่อง มักอยู่ในรูปของจำนวนเต็ม ไม่สามารถแบ่งย่อยออกเป็นส่วนเล็กๆ ได้ เช่น จำนวนพนักงานในแผนก 60 คน
- Continuous data (ข้อมูลแบบต่อเนื่อง): ข้อมูลที่วัดค่าได้ภายในช่วงที่กำหนด และข้อมูลเป็นค่าที่ต่อเนื่อง เช่น ส่วนสูง อุณหภูมิ น้ำหนัก

- Nominal data (ข้อมูลนามบัญญัติ): จำแนกประเภทของคุณลักษณะหรือสิ่งของต่างๆ เช่น กรุ๊ปเลือด A, B, C, O, AB
- Ordinal data (ข้อมูลเชิงอันดับ): เเรียงอันดับ สิ่งต่างๆ ตามลักษณะหนึ่งๆ เช่น ระดับของลูกค้า Platinum, Gold, Silver

การรวบรวมข้อมูล (DATA COLLECTION)

สัมภาษณ์ สังเกต ทดลอง แบบสอบถาม

ฐานข้อมูลในองค์กร

แหล่งข้อมูลภายนอก

ชุดข้อมูล (Data Set) มาตรฐาน

ฯลฯ

DATA PREPARATION

กระบวนการนำข้อมูลดิบที่รวมมาจัดเตรียมให้อยู่ในรูปแบบที่พร้อมสำหรับการวิเคราะห์



การสกัดข้อมูล (Data extraction)



การรวมข้อมูล (Data integration)



การแปลงข้อมูล (Data transformation)



การลดรูปข้อมูล (Data reduction)

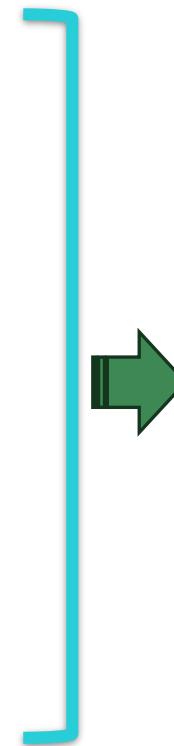


การทำความสะอาดข้อมูล (Data cleansing)

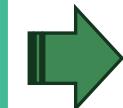
การสกัดข้อมูล (DATA EXTRACTION)

เป็นการคัดข้อมูลที่ไม่เกี่ยวข้องออกไปจากกลุ่มตัวอย่าง
สกัดเอาเฉพาะบาง Field หรือบาง Column ที่ไม่เกี่ยวข้องออกไปจากข้อมูล
การคัดเลือกเฉพาะข้อมูลที่เราสนใจมาวิเคราะห์

- รหัสนักศึกษา
- ชื่อนักศึกษา
- ระดับชั้นปี
- สาขาวิชา
- คณะ
- จำนวนหน่วยกิตที่เรียน
- เกรดเฉลี่ยสะสม
- อาจารย์ที่ปรึกษา
- ที่อยู่
- เบอร์โทรศัพท์



กำหนดแนวโน้ม
การผันสภาพของนักศึกษา

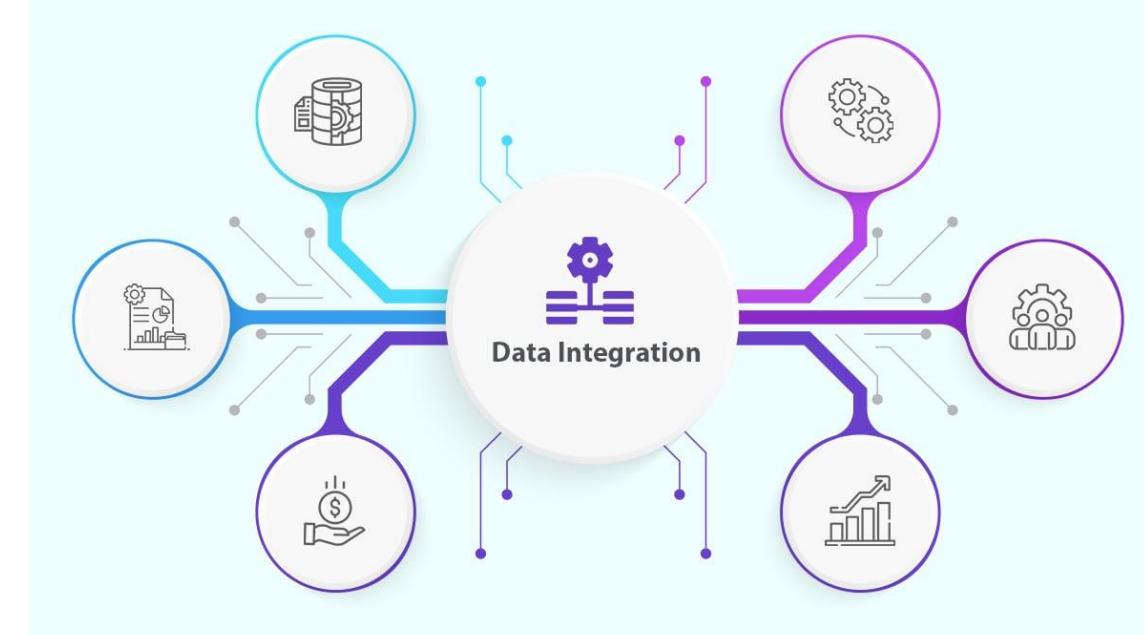


- รหัสนักศึกษา
- ชื่อนักศึกษา
- ระดับชั้นปี
- สาขาวิชา
- คณะ
- จำนวนหน่วยกิตที่เรียน
- เกรดเฉลี่ยสะสม

การรวมข้อมูล (DATA INTEGRATION)

เป็นขั้นตอนการรวมข้อมูลจากแหล่งข้อมูล ซึ่งมีข้อมูลหลากหลายมารวมไว้ที่เดียวกัน

- ปัญหาความไม่สอดคล้องกันของข้อมูล
- ประเภทของข้อมูลแตกต่างกัน
- รูปแบบการจัดเก็บข้อมูลที่แตกต่างกัน



การรวมข้อมูล (DATA INTEGRATION)

แหล่งข้อมูลที่ 1				แหล่งข้อมูลที่ 2				
รหัสนักศึกษา	Assignment Score	Final Score	ผลการเรียน	รหัสนักศึกษา	ชื่อ-นามสกุล	คะแนนเก็บ (เต็ม 30 คะแนน)	คะแนนสอบ (เต็ม 70 คะแนน)	ผลการเรียน
1010	A	99	Pass	115	John Doe	30	68	ผ่าน
1012	B	80	Fail	116	James Johnson	25	67	ไม่ผ่าน
1013	B	75	Pass	117	Maxim Gates	20	25	ไม่ผ่าน

การรวมข้อมูล (DATA INTEGRATION)

แหล่งข้อมูลที่ 1				แหล่งข้อมูลที่ 2
รหัสนักศึกษา	Assignment Score	Final Score	ผลการเรียน	
1010	A	99	Pass	ต.ย. ปัญหาจากการใช้รหัส แทนค่าข้อมูลแตกต่างกัน
1012	B	80	Fail	
1013	B	75	Pass	

รหัสนักศึกษา	ชื่อ-นามสกุล	คะแนนเก็บ (เต็ม 30 คะแนน)	คะแนนสอบ (เต็ม 70 คะแนน)	ผลการเรียน
115	John Doe	30	68	ผ่าน
116	James Johnson	25	67	ไม่ผ่าน
117	Maxim Gates	20	25	ไม่ผ่าน

การรวมข้อมูล (DATA INTEGRATION)

แหล่งข้อมูลที่ 1				แหล่งข้อมูลที่ 2
รหัสนักศึกษา	Assignment Score	Final Score	ผลการเรียน	ผลการเรียน
1010	A	99	Pass	ต.ย. ปัญหาจากการกำหนด รูปแบบการจัดเก็บข้อมูล แตกต่างกัน
1012	B	80	Fail	
1013	B	75	Pass	

รหัสนักศึกษา	ชื่อ-นามสกุล	คะแนนเก็บ (เต็ม 30 คะแนน)	คะแนนสอบ (เต็ม 70 คะแนน)	ผลการเรียน
115	John Doe	30	68	ผ่าน
116	James Johnson	25	67	ไม่ผ่าน
117	Maxim Gates	20	25	ไม่ผ่าน

การรวมข้อมูล (DATA INTEGRATION)

แหล่งข้อมูลที่ 1				แหล่งข้อมูลที่ 2
รหัสนักศึกษา	Assignment Score	Final Score	ผลการเรียน	ชื่อ-นามสกุล (เต็ม 30 คะแนน)
1010	A	99	Pass	ต.ย. ปัญหาจากการกำหนด มาตรฐานข้อมูลแตกต่างกัน
1012	B	80	Fail	
1013	B	75	Pass	

รหัสนักศึกษา	ชื่อ-นามสกุล	คะแนนเก็บ (เต็ม 30 คะแนน)	คะแนนสอบ (เต็ม 70 คะแนน)	ผลการเรียน
115	John Doe	30	68	ผ่าน
116	James Johnson	25	67	ไม่ผ่าน [No Title]
117	Maxim Gates	20	25	ไม่ผ่าน

การแปลงข้อมูล (DATA TRANSFORMATION)

เป็นขั้นตอนการแปลงข้อมูลให้มีความเหมาะสม มีมาตรฐานเดียวกัน

- เช่น การแปลงข้อมูล จาก เซนติเมตร เป็น เมตร
- จัดเก็บข้อมูลให้อยู่ในรูปแบบมาตรฐาน
- การปรับเปลี่ยนประเภทของข้อมูล



การลดรูปข้อมูล (DATA REDUCTION)

เป็นขั้นตอนการลดมิติข้อมูล เพื่อใช้ในเป็นตัวแทนข้อมูลทั้งหมดสำหรับการวิเคราะห์

ภาควิชา	ชื่อภาควิชา (ลดรูป)
วิทยาการคอมพิวเตอร์	CS
ธรณีวิทยา	GEOL
เคมี	CHEM
คณิตศาสตร์	MATH
ชีววิทยา	BIO

การทำความสะอาดข้อมูล (DATA CLEANSING)

เป็นขั้นตอนการตรวจสอบ แก้ไขข้อมูล โดยการคัดข้อมูลที่ไม่มีคุณภาพ หรือปรับปรุงข้อมูล เพื่อให้ได้ข้อมูลที่มีคุณภาพสำหรับการนำไปวิเคราะห์



ค่าข้อมูลที่เป็นค่าว่าง ขาดหาย (Missing Values)



ข้อมูลรบกวน (Noisy Data)



ข้อมูลไม่สอดคล้อง (Inconsistency Data)



ข้อมูลขาดรูปแบบ (Lack of uniformity Data)



ข้อมูลสะกดผิด (Misspellings Data)



ข้อมูลซ้ำ (Duplicate Data)

ค่าข้อมูลที่เป็นค่าว่าง ขาดหาย (MISSING VALUES)

รหัสนักศึกษา	คะแนนเก็บ (เต็ม 30 คะแนน)	คะแนนสอบ (เต็ม 70 คะแนน)	ผลการเรียน
111		69	ผ่าน
112	35	665	ผ่าน
113	20	1	ไม่ผ่าน
114	25	67	ผ่าน
115	30	68	ผ่าน
116	25	67	ไม่ผ่าน
117	10	40	ไม่ผ่าน
118	ขอ	65	ผ่าน

ข้อมูลรบกวน (NOISY DATA)

รหัสนักศึกษา	คะแนนเก็บ (เต็ม 30 คะแนน)	คะแนนสอบ (เต็ม 70 คะแนน)	ผลการเรียน
111		69	ผ่าน
112	35	665	ผ่าน
113	20	1	ไม่ผ่าน
114	25	67	ผ่าน
115	30	68	ผ่าน
116	25	67	ไม่ผ่าน
117	20	25	ไม่ผ่าน
118	ขอ恕	65	ผ่าน

Outliers
ค่าผิดปกติ

ข้อมูลรบกวน (NOISY DATA)

Error Values
ค่าผิดพลาด

รหัสนักศึกษา	ภาควิชา	คะแนนเก็บ (เต็ม 30 คะแนน)	คะแนนสอบ (เต็ม 70 คะแนน)	ผลการเรียน
111	Comp Sci		69	ผ่าน
112	Stat	35	665	ผ่าน
113	Maths	20	1	ไม่ผ่าน
114	maths	25	67	ผ่าน
115	Mathematics	30	68	ผ่าน
116	Computer Sc	25	67	ไม่ผ่าน
117	stat	20	25	ไม่ผ่าน
118	COMP	斛	65	ผ่าน

การจัดการข้อมูล MISSING VALUES/ NOISY DATA

1

ลบข้อมูลในระเบียนที่มีค่าหายไป

รหัสนักศึกษา	คะแนนเก็บ (เต็ม 30 คะแนน)
111	
112	35
113	20
114	25
115	30
116	25

2

ไม่นำค่าน้อยมาใช้ในการวิเคราะห์ข้อมูล

รหัสนักศึกษา	คะแนนเก็บ (เต็ม 30 คะแนน)
111	
112	35
113	20
114	25
115	30
116	25

3

ประมาณหรือเติมค่าที่ขาดหายไปด้วยค่าอื่น

รหัสนักศึกษา	คะแนนเก็บ (เต็ม 30 คะแนน)
111	30
112	35
113	20
114	25
115	30
116	25

แทนที่ด้วย

- ค่า เช่น N/A หรือ none หรือ null
- ค่าน้อยที่สุด ในกรณีที่แอดຕกริบิวต์ เป็นตัวเลข (numeric)
- ค่ามากที่สุด ในกรณีที่แอดຕกริบิวต์ เป็นตัวเลข (numeric)
- ค่าเฉลี่ย (mean/average) ในกรณีที่แอดຕกริบิวต์ เป็นตัวเลข (numeric)
- ค่าฐานนิยม (mode) ในกรณีที่แอดຕกริบิวต์ เป็นนกลุ่ม (nominal)
- ค่า 0 เช่น จำนวนบุตร
- ค่าที่ระบุเอง เช่น ไม่ระบุ

ข้อมูลไม่สอดคล้อง (INCONSISTENCY DATA)

รหัสนักศึกษา	คะแนนเก็บ (เต็ม 30 คะแนน)	คะแนนสอบ (เต็ม 70 คะแนน)	ผลการเรียน
111		69	ผ่าน
112	35	665	ผ่าน
113	20	1	ไม่ผ่าน
114	25	67	ผ่าน
115	30	68	ผ่าน
116	25	67	ไม่ผ่าน
117	20	25	ไม่ผ่าน
118	ขอ	65	ผ่าน

วิธีจัดการวิธี INCONSISTENCY DATA

1
จัดเรียงข้อมูลในกลุ่มที่อาจทำให้เกิดการไม่สอดคล้องใหม่

รหัสนักศึกษา	คะแนนเก็บ (เต็ม 30 คะแนน)	คะแนนสอบ (เต็ม 70 คะแนน)	ผลการเรียน
113	20	1	ไม่ผ่าน
117	20	25	ไม่ผ่าน
114	25	67	ผ่าน
116	25	67	ไม่ผ่าน
115	30	68	ผ่าน
112	35	665	ผ่าน
118	ขส	65	ผ่าน
111		69	ผ่าน

2
ทำการแก้ไขข้อมูลที่ไม่สอดคล้อง

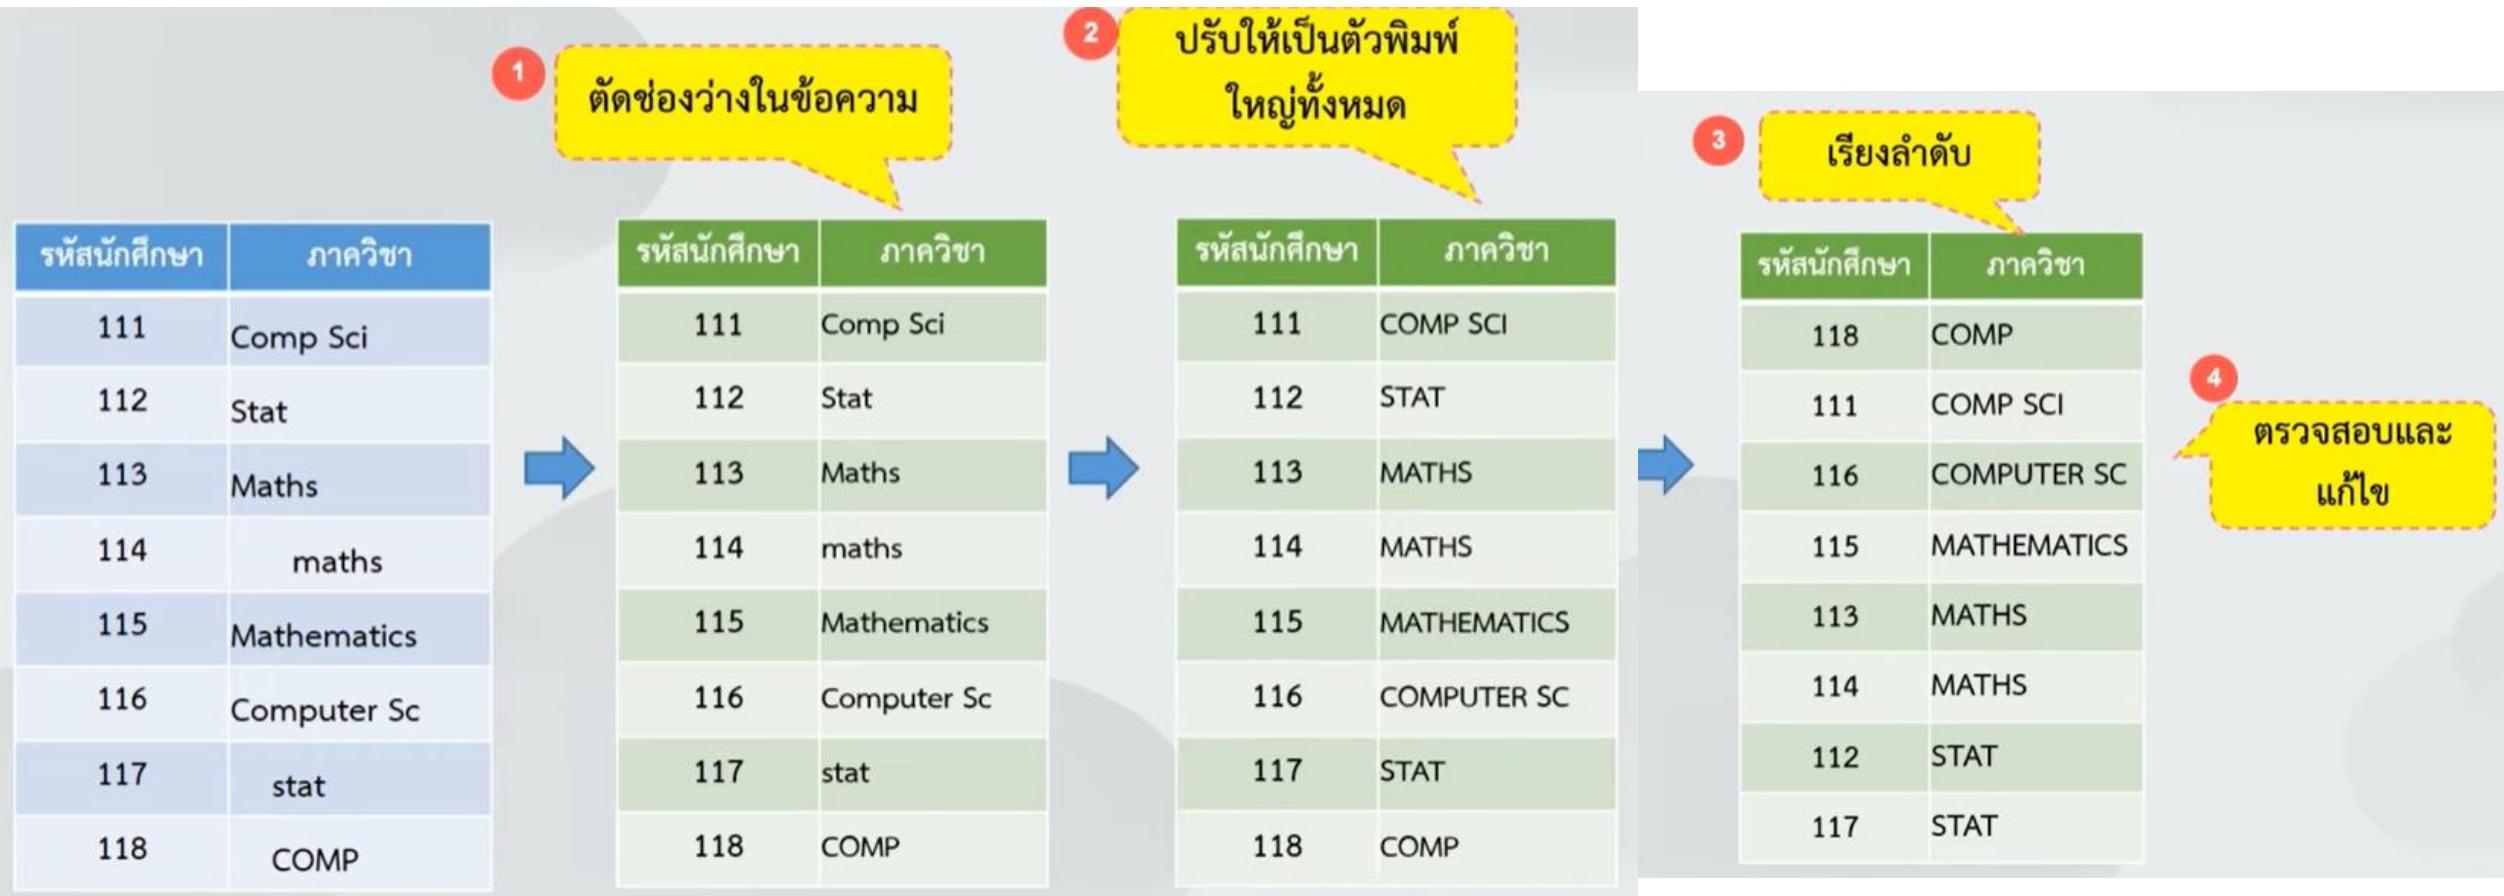
ข้อมูลขาดรูปแบบ (LACK OF UNIFORMITY DATA)

รหัสนักศึกษา	ภาควิชา
111	Comp Sci
112	Stat
113	Maths
114	maths
115	Mathematics
116	Computer Sc
117	stat
118	COMP

ข้อมูลสะกดผิด (MISSPELLINGS DATA)

รหัสนักศึกษา	ภาควิชา	ลงทะเบียนเข้าอบรม
111	Comp Sci	ลงทะเบียน
112	Stat	ไม่ลงทะเบียน
113	Maths	ไม่ลงทะเบียน
114	maths	ลงทะเบียน
115	Mathematics	ลงทะเบียน
116	Computer Sc	ไม่ลงทะเบียน
117	Statics	ลงทะเบียน
111	Comp	ลงทะเบียน
118	Maht	ลงทะเบียน

การแก้ปัญหา MISSPELLINGS DATA



ข้อมูลซ้ำ (DUPLICATE DATA)

ชื่อ-นามสกุล	ลงทะเบียนเข้าอบรม
James Johnson	Jame@gmail.com
Maxim Gates	Maxim@gmail.com
Sarah Lily	Sarah.L@gmail.com
Katie Smith	Katie.sm@gmail.com
Sarah Lily	Sarah.L@gmail.com
John Doe	John.d@gmail.com
James Johnson	Jame@gmail.com
Maxim Gates	Maxim@gmail.com

การแก้ปัญหา DUPLICATE DATA

The diagram illustrates the process of identifying and handling duplicate data in a dataset. It consists of two main parts: 1) Identifying duplicates (จัดเรียงข้อมูล) and 2) Handling duplicates (ตัดข้อมูลซ้ำ).

1. **จัดเรียงข้อมูล**: This step shows a table with data rows highlighted by colored dashed boxes. The first row (James Johnson) is highlighted with a red dashed box. The second row (James Johnson) is highlighted with a green dashed box. The fourth row (Maxim Gates) is highlighted with a blue dashed box. The fifth row (Sarah Lily) is highlighted with a green dashed box.

2. **ตัดข้อมูลซ้ำ**: This step shows the same table, but the second row (James Johnson) and the fifth row (Sarah Lily) have been removed, indicated by a red circle with the number 2.

ชื่อ-นามสกุล	ลงทะเบียนเข้าอบรม
James Johnson	Jame@gmail.com
James Johnson	Jame@gmail.com
John Doe	John.d@gmail.com
Katie Smith	Katie.sm@gmail.com
Maxim Gates	Maxim@gmail.com
Maxim Gates	Maxim@gmail.com
Sarah Lily	Sarah.L@gmail.com
Sarah Lily	Sarah.L@gmail.com



END